

Cảnh báo sớm nhiễm khuẩn huyết trong ICU bằng Big Data và MLOps

Giảng viên hướng dẫn

TS. Trần Hồng Việt & ThS. Ngô Minh Hương

Nhóm sinh viên thực hiện

Lê Thiện Đức 23020358

Nguyễn Đức Huy 23020376

Trường Đại học Công nghệ – Đại học Quốc gia Hà Nội

Hà Nội, Tháng 6 năm 2026

Nội dung báo cáo

- 1 Giới thiệu & Bối cảnh
- 2 Kiến trúc Hệ thống
- 3 Quy trình MLOps & Tái huấn luyện
- 4 Dữ liệu & Kết quả đánh giá
- 5 Vận hành Dashboard
- 6 Kết luận

Giới thiệu & Bối cảnh

Vì sao cần giám sát bệnh nhân ICU?

- **ICU là môi trường có rủi ro cao:**

- Bệnh nhân thường đang trong tình trạng nặng và có thể thay đổi rất nhanh.
- Một thay đổi nhỏ ở nhịp tim, huyết áp, oxy máu hoặc xét nghiệm có thể là dấu hiệu cảnh báo sớm.

- **Sepsis khó phát hiện ở giai đoạn đầu:**

- Dấu hiệu ban đầu thường không rõ ràng và nằm rải rác trên nhiều chỉ số.
- Nếu phát hiện muộn, nguy cơ biến chứng và tử vong tăng cao.

- **Vấn đề đặt ra:**

- Cần một hệ thống theo dõi dữ liệu liên tục, xử lý nhanh và hỗ trợ cảnh báo sớm.
- Big Data và streaming phù hợp vì dữ liệu ICU là dữ liệu chuỗi thời gian phát sinh liên tục.

Giới thiệu & Bối cảnh

Dữ liệu ICU gồm những chỉ số nào?

Dữ liệu sử dụng

Bộ dữ liệu được lấy từ PhysioNet/CinC Challenge 2019, gồm hai phần **Training Set A** và **Training Set B**. Mỗi bệnh nhân là một file PSV, mỗi dòng là một giờ theo dõi trong ICU.

Dấu hiệu sinh tồn

- **HR:** nhịp tim.
- **O2Sat:** độ bão hòa oxy máu.
- **Temp:** nhiệt độ cơ thể.
- **SBP, MAP, DBP:** huyết áp.
- **Resp:** nhịp thở.

Xét nghiệm và thông tin nền

- **Lactate, WBC:** liên quan nhiễm trùng và phản ứng viêm.
- **Creatinine, BUN:** phản ánh chức năng thận.
- **Platelets, Hgb:** chỉ số huyết học.
- **Age, Gender, ICULOS:** tuổi, giới tính, số giờ nằm ICU.

Ý tưởng chính: Không nhìn từng chỉ số riêng lẻ, hệ thống học xu hướng thay đổi của nhiều chỉ số theo thời gian để dự đoán nguy cơ Sepsis.

Sepsis (Nhiễm khuẩn huyết) là gì?

Là tình trạng cơ thể phản ứng quá mức với nhiễm trùng, có thể gây suy cơ quan và là một trong những tình trạng nguy hiểm tại khoa ICU.

● **Khó phát hiện sớm:**

- Dấu hiệu ban đầu thường mờ nhạt, không xuất hiện rõ trên một chỉ số duy nhất.
- Nhiều chỉ số thay đổi cùng lúc nhưng mức thay đổi có thể nhỏ và rải rác theo thời gian.

● **Cần cảnh báo trước khi bệnh nhân chuyển nặng:**

- Nếu phát hiện nguy cơ sớm hơn vài giờ, đội ngũ y tế có thêm thời gian kiểm tra và can thiệp.
- Hệ thống cần theo dõi xu hướng của bệnh nhân thay vì chỉ nhìn một lần đo tại một thời điểm.

Giới thiệu & Bối cảnh

Mục tiêu đề tài: xây dựng pipeline Big Data

Mục tiêu tổng quát

Xây dựng hệ thống mô phỏng giám sát bệnh nhân ICU gần thời gian thực, từ dữ liệu PSV đầu vào đến kết quả cảnh báo Sepsis trên dashboard.

PSV → NiFi → Kafka → Spark Streaming → Cassandra/HDFS → Flask API → Dashboard

- **Đưa dữ liệu vào hệ thống:**

- Đọc dữ liệu bệnh nhân ICU từ các file PSV.
- Chuyển dữ liệu sang JSON và gửi vào Kafka topic `icu_data`.

- **Xử lý realtime bằng Spark Streaming:**

- Xử lý dữ liệu theo từng bệnh nhân thay vì từng dòng độc lập.
- Lưu kết quả vào Cassandra cho truy vấn nhanh và HDFS cho dữ liệu lịch sử.

Giới thiệu & Bối cảnh

Mục tiêu đề tài: dự đoán và hiển thị cảnh báo

- **Dự đoán nguy cơ Sepsis bằng mô hình AI:**

- Huấn luyện mô hình XGBoost trên dữ liệu PhysioNet/CinC Challenge 2019.
- Sử dụng cửa sổ 6 giờ gần nhất để mô hình học xu hướng thay đổi của bệnh nhân.
- Trả ra xác suất Sepsis và trạng thái cảnh báo.

- **Tích hợp MLOps:**

- Airflow hỗ trợ lập lịch huấn luyện lại mô hình khi có thêm dữ liệu.
- MLflow lưu metric, artifact và thông tin phiên bản mô hình.

- **Trực quan hóa kết quả:**

- Dashboard hiển thị chỉ số ICU, xác suất Sepsis và cảnh báo theo thời gian.
- Người dùng có thể chọn bệnh nhân, chạy demo realtime và quan sát diễn biến từng giờ.

Kiến trúc Hệ thống

Kiến trúc tổng thể

Hệ thống được chia thành nhiều tầng để mỗi thành phần chỉ tập trung vào một nhiệm vụ chính. Nhờ vậy, dữ liệu có thể đi từ file PSV ban đầu đến dashboard mà không bị phụ thuộc vào một chương trình xử lý duy nhất.

Luồng xử lý thời gian thực

PSV → NiFi → Kafka → Spark Streaming → XGBoost → Cassandra/HDFS

Luồng phục vụ dữ liệu cho dashboard

Cassandra/HDFS → Flask API → Nginx → Dashboard → Người dùng

Nhánh MLOps

Dữ liệu lịch sử → Airflow → Huấn luyện lại → MLflow → Mô hình mới

Kiến trúc Hệ thống

Tầng thu thập và truyền dữ liệu

Apache NiFi

- Theo dõi thư mục dữ liệu mô phỏng thời gian thực.
- Đọc từng file PSV, mỗi file tương ứng với một bệnh nhân.
- Bổ sung mã bệnh nhân từ tên file.
- Chuyển dữ liệu dạng bảng sang JSON để đưa vào luồng streaming.
- Có thể lưu bản thô lên HDFS để kiểm tra lại khi cần.

Apache Kafka

- Nhận dữ liệu JSON từ NiFi.
- Đóng vai trò hàng đợi trung gian giữa NiFi và Spark.
- Giúp hệ thống không bị nghẽn khi dữ liệu vào nhanh hơn tốc độ xử lý.
- Spark có thể đọc tiếp dữ liệu còn trong Kafka khi sẵn sàng.

Kiến trúc Hệ thống

Tầng xử lý streaming và dự đoán

- **Spark Streaming** đọc dữ liệu từ Kafka và chuyển JSON về dạng bảng có schema rõ ràng.
- Dữ liệu được xử lý theo từng bệnh nhân, vì bài toán Sepsis phụ thuộc vào diễn biến nhiều giờ chứ không chỉ một bản ghi đơn lẻ.
- Spark giữ chuỗi dữ liệu gần đây của bệnh nhân, xử lý thiếu dữ liệu, chuẩn hóa và tạo đặc trưng theo cửa sổ thời gian.
- Mô hình **XGBoost** nhận đặc trưng từ Spark và trả ra xác suất nguy cơ Sepsis tại từng thời điểm.
- Từ xác suất dự đoán, hệ thống sinh thêm trạng thái cảnh báo sớm và cảnh báo xác nhận để dashboard hiển thị dễ hiểu hơn.

Kiến trúc Hệ thống

Tầng lưu trữ dữ liệu

Cassandra

- Lưu dữ liệu đã xử lý theo bệnh nhân và thời gian ICU.
- Phù hợp với truy vấn nhanh cho dashboard.
- Lưu các chỉ số ICU, xác suất Sepsis và trạng thái cảnh báo.
- Được dùng làm nguồn đọc ưu tiên khi dashboard cần dữ liệu mới.

HDFS

- Lưu dữ liệu lịch sử dạng Parquet.
- Phù hợp cho lưu trữ dài hạn và xử lý theo lô.
- Là nguồn dự phòng khi Cassandra chưa có dữ liệu.
- Có thể dùng làm dữ liệu đầu vào cho quy trình huấn luyện lại.

Kiến trúc Hệ thống

Tầng phục vụ dashboard và nhánh MLOps

- **Flask API** là lớp trung gian giữa dashboard và tầng lưu trữ, giúp giao diện không phải truy cập trực tiếp vào Cassandra hoặc HDFS.
- API ưu tiên đọc Cassandra để lấy dữ liệu mới; nếu chưa có dữ liệu thì chuyển sang HDFS hoặc file PSV dùng cho demo.
- **Nginx** đứng trước API để người dùng truy cập qua một địa chỉ thống nhất và có thể chia tải cho nhiều API server.
- **Dashboard** hiển thị các nhóm chỉ số ICU, xác suất Sepsis, ngưỡng dự đoán và marker cảnh báo theo thời gian.
- **Airflow và MLflow** tạo nhánh MLOps: lập lịch huấn luyện lại, lưu metric, lưu artifact và quản lý phiên bản mô hình.

Quy trình MLOps

Vì sao cần huấn luyện lại mô hình?

- Mô hình ban đầu được huấn luyện và export sẵn để Spark Streaming có thể nạp trực tiếp khi hệ thống chạy.
- Khi pipeline vận hành, HDFS có thể thêm dữ liệu lịch sử từ các lần mô phỏng hoặc các đợt dữ liệu mới.
- Nếu chỉ dùng một mô hình cố định, chất lượng dự đoán có thể giảm khi dữ liệu mới khác với dữ liệu huấn luyện ban đầu.
- Nhánh MLOps giúp tự động hóa các bước: kiểm tra dữ liệu mới, huấn luyện lại, lưu kết quả và so sánh với mô hình hiện tại.
- Mục tiêu là cập nhật mô hình có kiểm soát, không thay mô hình chỉ vì có một lần train mới.

Quy trình MLOps

Airflow điều phối quá trình huấn luyện

- **Airflow** chạy workflow huấn luyện theo lịch định kỳ hoặc khi người dùng kích hoạt.
- Quy trình bắt đầu bằng việc kiểm tra dữ liệu mới trong các nguồn dữ liệu của hệ thống, đặc biệt là dữ liệu lịch sử trên HDFS.
- Khi dữ liệu đủ điều kiện, Airflow gọi tiến trình huấn luyện để tạo lại tập đặc trưng và huấn luyện XGBoost.
- Dữ liệu train được xử lý thống nhất với luồng realtime:
 - xử lý giá trị thiếu;
 - chuẩn hóa theo thống kê huấn luyện;
 - tạo delta, missing mask và cửa sổ thời gian 6 giờ.
- Cách này giúp mô hình khi train và khi chạy realtime nhận cùng một kiểu đầu vào.

Quy trình MLOps

MLflow theo dõi và so sánh các lần train

- **MLflow** ghi lại thông tin của từng lần huấn luyện để nhóm có thể xem lại và so sánh.
- Các thông tin được lưu gồm:
 - tham số huấn luyện của XGBoost;
 - các độ đo như ROC-AUC, AUCPR, Recall và Utility Score;
 - mô hình, scaler, metadata và các biểu đồ đánh giá.
- Sau khi train xong, mô hình mới được so sánh với mô hình đang dùng trên tập validation hoặc test cố định.
- Nếu kết quả không tốt hơn, hoặc làm giảm rõ rệt các chỉ số quan trọng như AUCPR, nhóm giữ lại mô hình cũ.
- Nếu mô hình mới ổn định hơn, model artifact và metadata có thể được dùng để cập nhật cho Spark Streaming.

Dữ liệu & Kết quả đánh giá

Đặc điểm tập dữ liệu huấn luyện

Dữ liệu được lấy từ PhysioNet/CinC Challenge 2019, gồm Training Set A và Training Set B. Khi chia train, validation và test, nhóm chia theo bệnh nhân để tránh một bệnh nhân xuất hiện ở nhiều tập khác nhau.

Đặc điểm thống kê	Giá trị
Tổng số bệnh nhân trong tập dữ liệu	40,336
Số bệnh nhân bị Sepsis (Nhãn dương)	2,932 (7.27%)
Số bệnh nhân không bị Sepsis (Nhãn âm)	37,404 (92.73%)
Tỷ lệ bệnh nhân Sepsis : Không Sepsis	1 : 12.76
Phân chia số lượng tập Train / Validation / Test	28,235 / 6,050 / 6,051
Tổng số giờ theo dõi sau khi tạo đặc trưng	1,552,210
Tỷ lệ giờ có nhãn Sepsis	1.80%
Trọng số lớp dương khi huấn luyện	54.54

Bảng: Thống kê đặc điểm tập dữ liệu

Dữ liệu & Kết quả đánh giá

Điểm cần chú ý khi đánh giá mô hình

- Bộ dữ liệu bị mất cân bằng rõ rệt: số bệnh nhân Sepsis chỉ chiếm khoảng 7.27%.
- Nếu xét theo từng giờ theo dõi, nhãn Sepsis còn hiếm hơn, chỉ khoảng 1.80%.
- Vì vậy, độ chính xác tổng thể không phải là thước đo phù hợp. Mô hình có thể đạt điểm cao nếu dự đoán phần lớn là không Sepsis.
- Nhóm ưu tiên các độ đo phản ánh khả năng phát hiện lớp dương như AUCPR, Recall và Utility Score.
- Khi huấn luyện, lớp Sepsis được gán trọng số cao hơn để mô hình chú ý hơn đến các trường hợp nguy cơ.

Dữ liệu & Kết quả đánh giá

Hiệu năng của mô hình XGBoost

Sau khi huấn luyện, mô hình trả ra xác suất Sepsis tại từng thời điểm. Ngưỡng dự đoán được chọn theo Utility Score thay vì dùng mặc định 0.5.

Ngưỡng dự đoán được chọn = 0.53

Độ đo (Metric)	Tập Validation	Tập Test
ROC-AUC	0.8303	0.8444
Average Precision (AUCPR)	0.0943	0.1311
Recall	0.6367	0.6617
Precision	0.0693	0.0707
F1-score	0.1250	0.1277
Normalized Utility Score	0.3963	0.4187

Bảng: Bảng so sánh hiệu năng mô hình trên tập Validation và Test

Nhận xét: Precision còn thấp do dữ liệu mất cân bằng mạnh. Tuy nhiên, Recall và Utility Score có ý nghĩa hơn trong bài toán này vì hệ thống ưu tiên cảnh báo sớm, giảm nguy cơ bỏ sót bệnh nhân có Sepsis.


Vận hành Dashboard

Dashboard ICU Patient Watch

- Dashboard là nơi người dùng theo dõi kết quả cuối cùng của toàn bộ pipeline.
- Người dùng có thể nhập mã bệnh nhân, chọn bệnh nhân mẫu, tải dữ liệu hiện có hoặc chạy chế độ demo theo thời gian.
- Dữ liệu được hiển thị theo từng giờ ICU, giúp quan sát diễn biến của bệnh nhân thay vì chỉ nhìn một giá trị đơn lẻ.
- Các nhóm biểu đồ chính gồm:
 - dấu hiệu sinh tồn và huyết áp;
 - xét nghiệm, khí máu, điện giải, chức năng gan thận;
 - xác suất Sepsis và trạng thái cảnh báo.
- Khi chạy demo realtime, biểu đồ được cập nhật dần theo thời gian để mô phỏng quá trình theo dõi bệnh nhân trong ICU.


Vận hành Dashboard

Theo dõi chỉ số ICU theo thời gian



Vận hành Dashboard

Theo dõi xác suất Sepsis và cảnh báo



Kết luận & Hướng phát triển

Kết luận đạt được

Kết quả đạt được

Xây dựng thành công hệ thống Big Data tích hợp pipeline streaming và quy trình MLOps hoàn chỉnh phục vụ bài toán cảnh báo sớm Sepsis trong ICU.

- **Mô phỏng được luồng dữ liệu ICU:** Dữ liệu bệnh nhân được đưa vào theo từng giờ, gần với cách dữ liệu phát sinh trong quá trình theo dõi thực tế.
- **Tách rõ các tầng xử lý:** NiFi, Kafka, Spark, Cassandra/HDFS, API và dashboard đảm nhiệm các vai trò riêng, giúp hệ thống dễ theo dõi và mở rộng.
- **Đảm bảo chất lượng mô hình:** Có quy trình huấn luyện lại định kỳ, ghi lại kết quả bằng MLflow và chỉ cập nhật khi mô hình mới đạt chất lượng phù hợp.

Kết luận & Hướng phát triển

Hướng phát triển tương lai

- **Cải thiện mô hình dự đoán:**

- Thử thêm LightGBM, CatBoost, LSTM hoặc Transformer và so sánh trên cùng tập validation/test.

- **Bổ sung đặc trưng theo thời gian:**

- Thêm trung bình trượt, độ dốc thay đổi và thời gian từ lần đo gần nhất của từng chỉ số.

- **Giải thích kết quả dự đoán:**

- Tích hợp SHAP hoặc LIME để biết chỉ số nào ảnh hưởng nhiều đến cảnh báo tại từng thời điểm.

Cảm ơn Thầy Cô và các bạn đã lắng nghe !.